
Rapport de projet fil rouge

Thomas Andrey
Yves Landry Bayoi Mahop
Etienne Vaneecloo

MS SIO 2023-2024



CentraleSupélec

Résumé

Le rapport détaille l'architecture d'un système de réponse automatique alimenté par l'intelligence artificielle. Il décrit en profondeur le processus d'ingestion d'articles, illustrant comment les données sont recueillies et traitées pour fournir des réponses précises aux utilisateurs. En outre, il expose la méthodologie de génération de réponses, démontrant comment les informations extraites sont utilisées pour répondre à diverses questions. Malgré les avancées significatives, le rapport met en lumière des défis tels que les limites quant au nombre d'articles accessibles et les considérations financières associées à l'utilisation de l'API.

Cependant, il conclut en soulignant l'engagement envers l'innovation continue et l'amélioration de l'expérience utilisateur, tout en reconnaissant la robustesse de l'architecture existante comme base solide pour répondre aux besoins évolutifs des utilisateurs.

Table des matières

1	Introduction	4
2	Architecture d'ensemble	5
2.1	Contexte	5
2.2	Containers	5
3	Technologies de l'architecture	7
3.1	Services tiers	7
3.1.1	API ArXiv	7
3.1.2	API ChatGPT	7
3.2	Stockage	8
3.2.1	Redis	8
3.2.2	GraphDB	8
3.2.3	Neo4j	9
3.3	Services applicatifs	9
3.3.1	Retreiver	10
3.3.2	Kong gateway	11
3.3.3	L'API	11
3.3.4	Asker	11
3.3.5	Updater	12
4	Knowledge Graph	13
4.1	Présentation du Knowledge Graph	13
4.2	Choix du Knowledge Graph	13
5	Ingestion d'un article	15
SIO 2023-2024	Rapport de projet fil rouge	2

6	Génération d'une réponse	16
6.1	Réponses aux questions	17
6.1.1	Qui influence qui?	17
6.1.2	Quels sont les meilleurs spécialistes de tel ou tel domaine? .	18
6.1.3	Quelles personnes influencent quelles autres personnes? . .	19
6.1.4	Qui est à l'origine de tel ou tel domaine technique?	20
7	Limites de l'architecture	21
8	Conclusion	22
9	Bibliographie et webographie	23
10	Annexes	24
10.1	Annexe I - Table des figures	24
10.2	Annexe II - OpenAPI	25

1 Introduction

L'essor exponentiel de la recherche en informatique et en intelligence artificielle (IA) a conduit à une abondance de connaissances et de publications, nécessitant des outils avancés pour extraire, organiser et exploiter efficacement ces données. Dans ce contexte, le présent projet vise à développer une architecture innovante pour l'analyse automatique des publications du site ArXiv.org dans les domaines de l'informatique et de l'IA, afin de répondre à diverses questions d'intérêt, telles que l'identification des tendances émergentes, l'identification des experts clés, la compréhension des influences entre chercheurs et l'origine des domaines techniques.

Cette architecture repose sur un pipeline de traitement modulaire composé de quatre modules principaux : l'extraction, le Traitement Automatique du Langage Naturel (TALN), la sémantisation et l'exploitation. Chaque module est conçu pour jouer un rôle spécifique dans le processus d'analyse et contribue à la génération de connaissances exploitables à partir des publications.

Le premier module, l'extraction, est chargé de collecter les métadonnées et les résumés des publications à partir du vaste corpus de données disponible sur ArXiv.org.

Le deuxième module, le Traitement Automatique du Langage Naturel (TALN), est chargé d'extraire les thèmes et les informations pertinentes à partir des résumés des publications.

Le troisième module, la sémantisation, consiste à organiser les informations extraites dans une structure de graphe de connaissances. Ce graphe permet de représenter les relations entre les différents concepts et entités présents dans les publications, facilitant ainsi la déduction de nouvelles propriétés et la mise en évidence de patterns et de tendances.

Enfin, le quatrième module, l'exploitation, est chargé de stocker le graphe de connaissances ainsi que les résultats des analyses réalisées. Il permet également de répondre aux requêtes des utilisateurs et de générer des visualisations interactives pour faciliter la compréhension et l'exploration des données.

Cette architecture a été conçue en tenant compte des défis spécifiques liés à l'analyse automatique de grandes quantités de données textuelles, notamment la variabilité du langage naturel, la diversité des sujets abordés et la nécessité de générer des résultats pertinents et exploitables. Les choix techniques et les performances du modèle seront discutés en détail dans la suite de ce rapport, mettant en lumière les avantages et les limitations de notre approche.

2 Architecture d'ensemble

2.1 Contexte

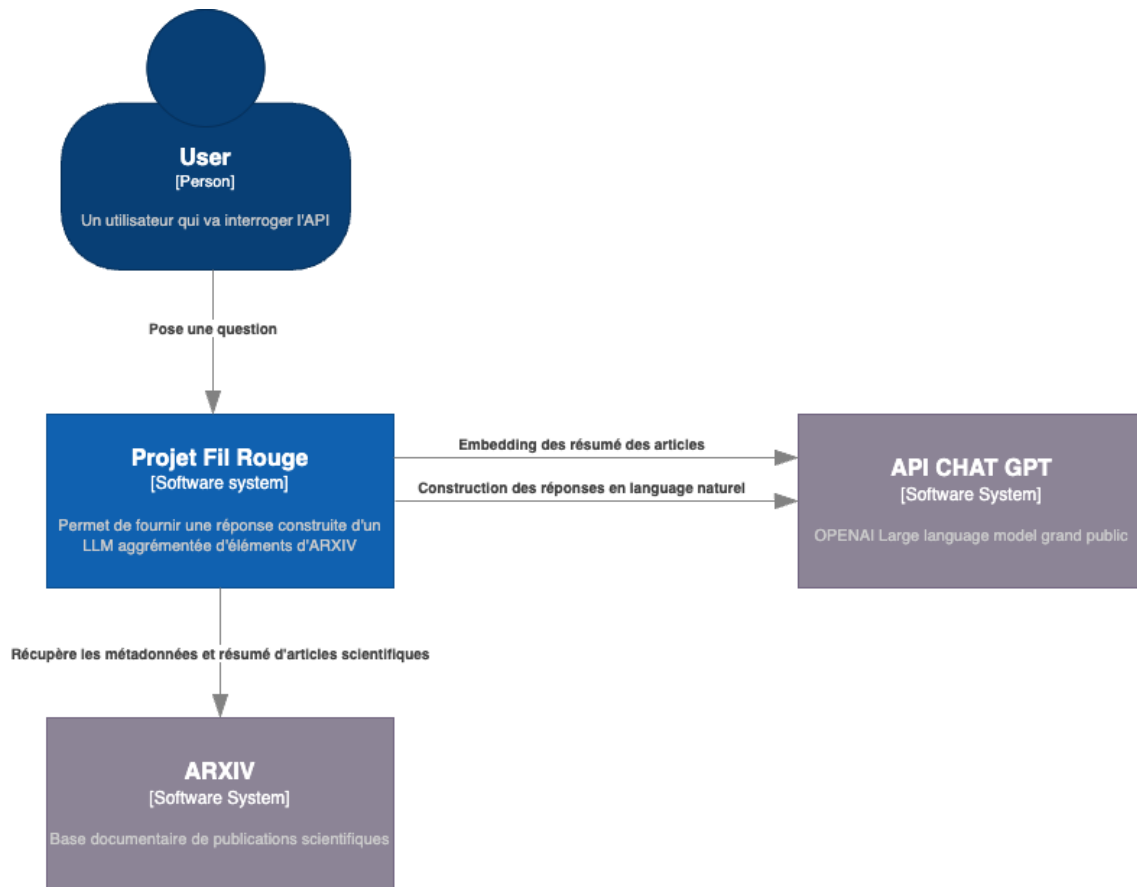


Figure 1 – Diagramme de contexte C4

2.2 Containers

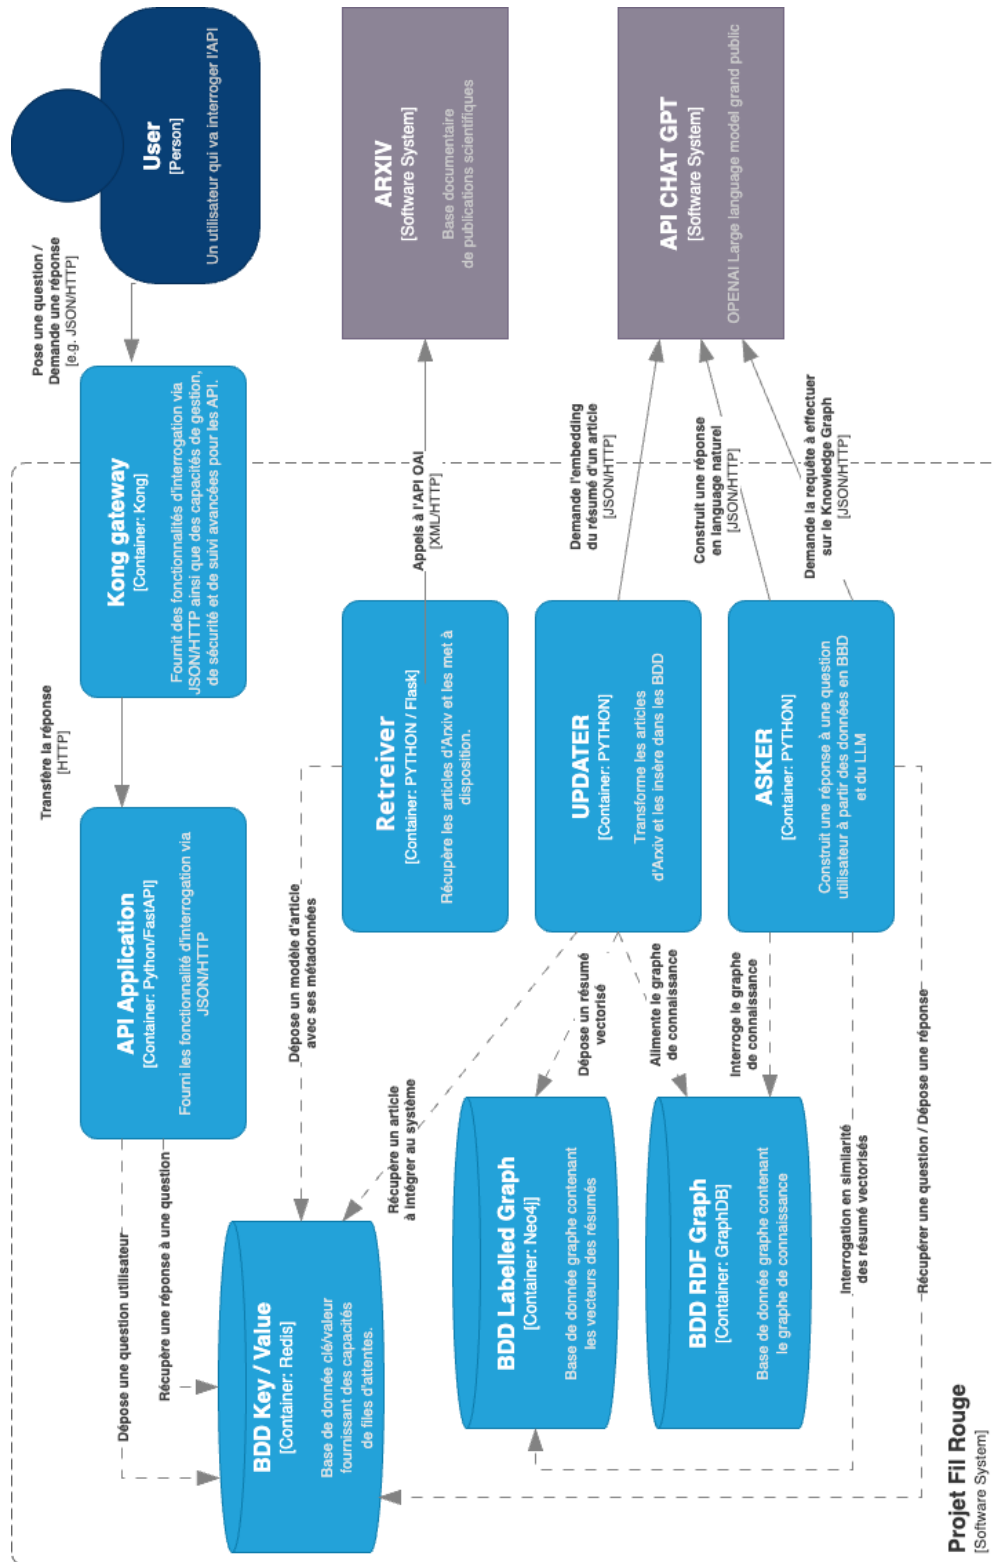


Figure 2 – Diagramme de containers C4

3 Technologies de l'architecture

3.1 Services tiers

3.1.1 API ArXiv

L'API ArXiv¹ [11] joue un rôle crucial dans l'accès aux articles scientifiques et académiques publiés sur la plateforme ArXiv. En tant que service de récupération et de distribution de pré-publications de recherches. L'API ArXiv permet de récupérer les métadonnées et un certain nombre d'articles auprès d'Arxiv, facilitant ainsi la recherche, l'exploration et l'analyse de données.

Pour les besoins du projet, nous utiliserons plus spécifiquement les endpoints permettant la récupération d'une grande quantité de données² [12] et supportant le protocole Open Archive Interface³ [13].

3.1.2 API ChatGPT

L'API ChatGPT⁴ [14] joue un rôle central dans l'intégration et l'utilisation de la technologie de génération de texte basée sur l'intelligence artificielle fournie par OpenAI. Cette API permet aux développeurs d'incorporer les capacités de ChatGPT dans diverses applications et systèmes, offrant ainsi la possibilité de générer du texte de manière fluide et contextuellement pertinente. L'API ChatGPT permet à l'updater d'effectuer l'embedding de l'abstract, ainsi que de générer la requête SPARQL⁵ [15] associée à la question et à la structure du Knowledge Graph.

1. ARXIV, arXiv API Access <https://info.arxiv.org/help/api/index.html>

2. ARXIV, arXiv Bulk Data Access - https://info.arxiv.org/help/bulk_data.html

3. Open Archives Initiative, Protocol for Metadata Harvesting - <http://www.openarchives.org/pmh/>

4. OPENAI, ChatGPT <https://chat.openai.com/>

5. W3C, SPARQL 1.1 Query Language - "SPARQL can be used to express queries across diverse data sources, whether the data is stored natively as RDF or viewed as RDF via middleware." - [urlhttps://www.w3.org/TR/sparql11-query/](https://www.w3.org/TR/sparql11-query/)

3.2 Stockage

3.2.1 Redis

Redis ⁶ est une base de données open-source clé/valeur en mémoire, souvent utilisée comme magasin de données en cache, système de messagerie, et pour des applications de traitement en temps réel.

Redis facilite la gestion des files d'attente pour les tâches à exécuter ⁷ entre différents services (Retreiver, Updater, API et Asker)

3.2.2 GraphDB

GraphDB ⁸ est une base de données orientée graphe qui permet de stocker, gérer et interroger des données sous forme de graphes RDF ⁹. Elle offre un modèle de données flexible et puissant, adapté à la représentation de relations complexes entre les entités.

GraphDB permet de stocker le graphe de connaissance au format RDF natif, et de faire des interrogations SparQL native via la spécification rdf4j ¹⁰.

	subject	↕	predicate	↕	object	↕
1	oai:arXiv.org:0710.3901		frbr:creator		pfr:Corneil-Derek	pfr:pfr
2	oai:arXiv.org:0710.3901		frbr:creator		pfr:Habil-Michel	pfr:pfr
3	oai:arXiv.org:0710.3901		frbr:creator		pfr:Paul-Christophe	pfr:pfr
4	oai:arXiv.org:0710.3901		frbr:creator		pfr:Tedder-Marc	pfr:pfr
5	oai:arXiv.org:0710.3901		frbr:subject		pfr:Computer-Science-Discrete-Mathematics	pfr:pfr
6	oai:arXiv.org:0710.3901		rdf:type		fabio:work	pfr:pfr
7	oai:arXiv.org:0710.3901		dcterms:date		"2007-10-20 00:00:00"	pfr:pfr
8	oai:arXiv.org:0710.3901		dcterms:date		"2024-03-01 00:00:00"	pfr:pfr
9	oai:arXiv.org:0710.3901		dcterms:title		"A recursive linear time modular decomposition algorithm via LexBFS"	pfr:pfr
10	oai:arXiv.org:0802.3284		frbr:creator		pfr:Bruyere-Veronique	pfr:pfr
11	oai:arXiv.org:0802.3284		frbr:creator		pfr:Melot-Hadrien	pfr:pfr
12	oai:arXiv.org:0802.3284		frbr:subject		pfr:Computer-Science-Discrete-Mathematics	pfr:pfr
13	oai:arXiv.org:0802.3284		rdf:type		fabio:work	pfr:pfr
14	oai:arXiv.org:0802.3284		dcterms:date		"2008-02-22 00:00:00"	pfr:pfr
15	oai:arXiv.org:0802.3284		dcterms:title		"Turan Graphs, Stability Number, and Fibonacci Index"	pfr:pfr

Figure 3 – Contenu de GraphDB

6. Redis, Homepage <https://redis.io/>
7. Redis, Redis Queue <https://redis.com/glossary/redis-queue/>
8. GraphDB, Homepage - <https://graphdb.ontotext.com/>
9. W3C, Resource Description Framework (RDF) - <https://www.w3.org/RDF/>
10. The Eclipse Foundation, RDF4J, RDF4J REST API (10) - <https://rdf4j.org/documentation/reference/rest-api/>

3.2.3 Neo4j

Neo4j¹¹ est une base de données orientée graphe hautement performante et évolutive. Elle est conçue pour stocker, gérer et interroger des données sous forme de graphes.

Neo4j permet de stocker les vectorisations des abstracts et rechercher en similarité native¹².

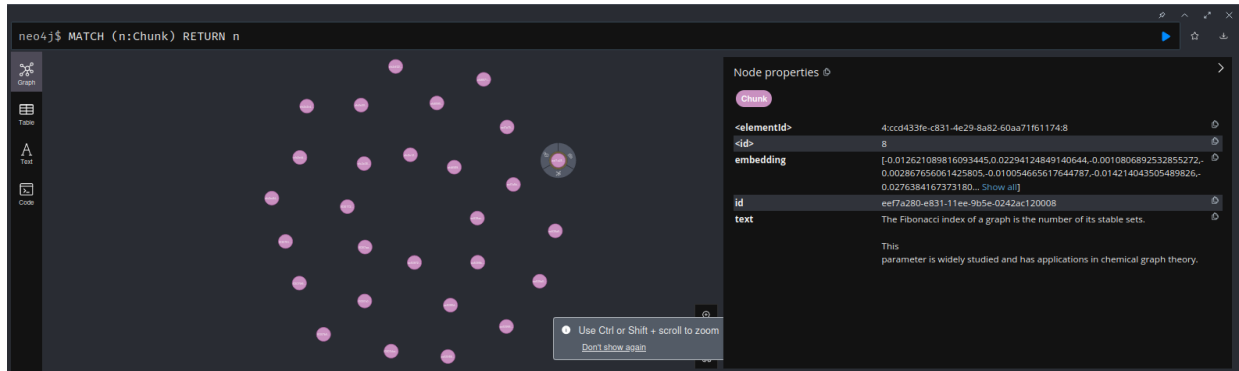


Figure 4 – Contenu de neo4j

3.3 Services applicatifs

La force de Python réside également dans ses limitations. En tant que langage dynamique, il requiert souvent l'utilisation de bibliothèques tierces pour contrôler et analyser les flux de données. Cependant, cette flexibilité peut également conduire à une complexité accrue dans les projets de grande envergure. Malgré cela, Python reste apprécié pour sa simplicité, sa lisibilité et son adaptabilité, offrant ainsi un cadre idéal pour développer des logiciels efficaces et faciles à comprendre.

Dans notre projet, nous avons opté pour une initialisation des services applicatifs au lancement de l'application et dans un ordre strictement défini. Les services dépendant d'autres services utilisent des instances préalablement initialisées, assurant ainsi un couplage faible entre ces briques logicielles.

11. NEO4J, Homepage - <https://neo4j.com/fr/>

12. NEO4J, Vector search indexes - <https://neo4j.com/docs/cypher-manual/current/indexes/semantic-indexes/vector-indexes/>

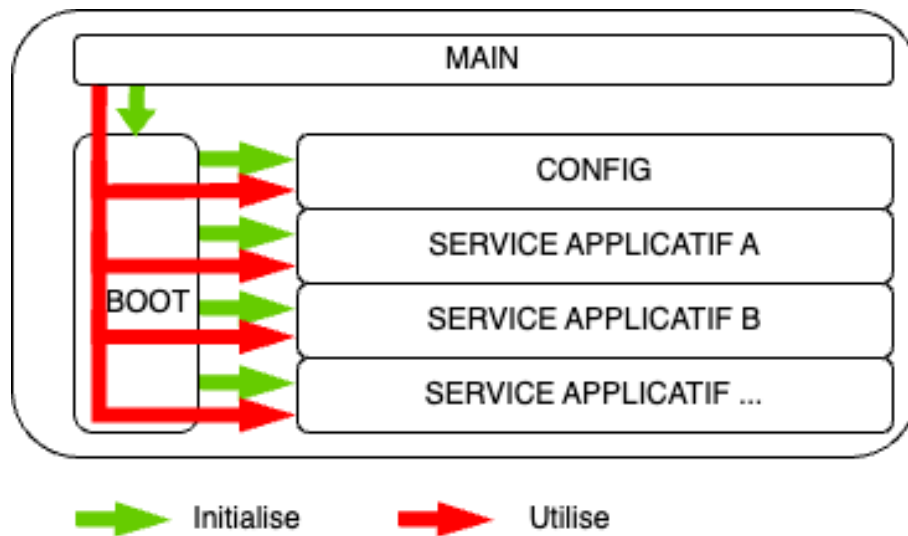


Figure 5 – Architecture d'un applicatif

3.3.1 Retreiver

Le Retreiver est le service permettant la récupération des articles depuis ARXiv. Il utilise pour cela les endpoints Open Archive Interface (OAI). A partir de la réponse XML, il vérifie le contenu de la liste d'article reçue et transforme ces derniers en un ensemble de modèles applicatifs. Par la suite, il dépose chaque modèle d'article dans une queue Redis L'API ARXiV transmet un maximum de 1000 Article en une réponse. Si la totalité des éléments à recevoir est supérieure, un token permettant de continuer les interrogations de l'API est associé à la réponse. Le Retreiver récupère cet élément et assure la continuation des requêtes tant que des articles sont à recevoir. Un délai d'attente est paramétré entre deux interrogations successives afin de satisfaire aux limiteurs de flux mis en place par ARXiv.

```
Application sélectionnée : retriever
--- Update retriever libraries.---
2024-03-22 09:52:32,213 - INFO - retriever.boot - === Begin ARXIV articles retrieval ===
2024-03-22 09:52:32,214 - INFO - retriever.boot - - Last retrieval time : Not found.
2024-03-22 09:52:32,214 - INFO - retriever.boot - - Limit number of articles : 5 articles.
2024-03-22 09:52:32,214 - INFO - retriever.boot - - Begin articles fetching.
2024-03-22 09:52:43,063 - INFO - retriever.boot - ---> 5 / 53676 articles (Limit: 5) | Arxiv response time : 10.74927
8520999724 s | Parse time : 0.09909104400048818 s
2024-03-22 09:52:46,067 - INFO - retriever.boot - - Fetch Done.
2024-03-22 09:52:46,067 - INFO - retriever.boot - === End of ARXIV articles retrieval ===
* Terminal will be reused by tasks, press any key to close it.
```

Figure 6 – Logs de fonctionnement du retriever.

On remarque la récupération des articles depuis arxiv, le total disponible et la limite de récupération paramétrée.

3.3.2 Kong gateway

Kong¹³ joue un rôle crucial en tant qu'interface entre notre API et les utilisateurs. En acceptant les requêtes API et en les dirigeant vers les services appropriés, Kong simplifie l'interaction utilisateur et garantit une gestion efficace du trafic. De plus, les extensions¹⁴ [8] et plugins disponibles dans Kong offrent un contrôle étendu sur les utilisateurs, permettant la mise en œuvre de politiques de sécurité avancées, la gestion des autorisations, et l'optimisation des performances des API, renforçant ainsi la fiabilité et la sécurité de notre architecture.

Dans notre projet, nous avons permis de mettre en place un mécanisme d'authentification via un password donnée en amont par l'utilisateur.

3.3.3 L'API

L'API Gateway¹⁵ [8] et l'API servent d'interface entre l'utilisateur et Redis. L'utilisateur requête l'API Gateway qui transmet au service API. Le service API génère un token UUID¹⁶ [5] qu'il associe à la question. Le token est retourné à l'utilisateur pour qu'il puisse venir récupérer sa réponse ultérieurement. Enfin, la question et son token associé sont déposés dans une queue Redis. Vous pourrez retrouver la documentation de l'API SWAGGER dans la section 10.2.

3.3.4 Asker

L'Asker sert d'interface entre l'API ChatGPT et les bases Redis, GraphDB et Neo4j. Il construit une réponse à une question posée à partir des données. L'asker en écoute permanente sur la queue, récupère la question et le token. Il demande à GraphDB la structure du knowledge graph et fait générer à ChatGPT la requête SPARQL. Il effectue une recherche en similarité de l'abstract sur Neo4j. Il dépose finalement la réponse associée au token dans Redis.

13. <https://konghq.com/>

14. <https://docs.konghq.com/hub/>

15. NGINX, API Gateway - "An API gateway accepts API requests from a client, processes them based on defined policies, directs them to the appropriate services, and combines the responses for a simplified user experience." - <https://www.nginx.com/learn/api-gateway/>

16. MOZILLA, Glossaire MDN, UUID - "Un identifiant universel unique (dont l'acronyme anglais est UUID pour Universally Unique Identifier) est un libellé utilisé pour identifier de façon unique une ressource parmi toutes les autres ressources du même type." - <https://developer.mozilla.org/fr/docs/Glossary/UUID>

3.3.5 Updater

L'Updater permet de transformer les articles pour les déposer dans les bases graphes. Il écoute en permanence une queue Redis des modèles ingérés par le Retreiver à transformer. L'updater sépare alors, pour chaque article, les éléments composants ce dernier. La donnée structurée est intégrée au graphe de connaissance stocké dans GraphDB. Le résumé de l'article est passé à ChatGPT qui va réaliser un embedding¹⁷ [9] de ce dernier et retourner un vecteur permettant une future recherche en similarité. Le vecteur en question sera déposé dans Neo4J.

```
2024-03-22 09:52:39,955 - INFO - updater.boot - === Start Updater main loop ===
2024-03-22 09:52:43,621 - INFO - updater.boot - Popped article : oai:arXiv.org:0710.3901
/usr/local/lib/python3.11/site-packages/spacy/pipeline/lemmatizer.py:211: UserWarning: [W108] The rule-based lemmatizer did not find POS annotations for one or more tokens. Check that your pipeline includes components that assign token.pos, typically 'tagger'+ 'attribute_ruler' or 'morphologizer'.
  warnings.warn(Warnings.W108)
2024-03-22 09:52:43,938 - WARNING - langchain_text_splitters.base - Created a chunk of size 226, which is longer than the specified 200
2024-03-22 09:52:44,180 - INFO - httpx - HTTP Request: POST https://api.openai.com/v1/embeddings "HTTP/1.1 200 OK"
2024-03-22 09:52:45,014 - INFO - updater.boot - Popped article : oai:arXiv.org:0802.3284
2024-03-22 09:52:45,388 - INFO - httpx - HTTP Request: POST https://api.openai.com/v1/embeddings "HTTP/1.1 200 OK"
2024-03-22 09:52:45,592 - INFO - updater.boot - Popped article : oai:arXiv.org:0802.3300
2024-03-22 09:52:45,728 - WARNING - langchain_text_splitters.base - Created a chunk of size 302, which is longer than the specified 200
2024-03-22 09:52:45,910 - INFO - httpx - HTTP Request: POST https://api.openai.com/v1/embeddings "HTTP/1.1 200 OK"
2024-03-22 09:52:46,095 - INFO - updater.boot - Popped article : oai:arXiv.org:0802.3414
2024-03-22 09:52:46,368 - WARNING - langchain_text_splitters.base - Created a chunk of size 202, which is longer than the specified 200
2024-03-22 09:52:46,368 - WARNING - langchain_text_splitters.base - Created a chunk of size 263, which is longer than the specified 200
2024-03-22 09:52:46,368 - WARNING - langchain_text_splitters.base - Created a chunk of size 217, which is longer than the specified 200
2024-03-22 09:52:46,368 - WARNING - langchain_text_splitters.base - Created a chunk of size 230, which is longer than the specified 200
2024-03-22 09:52:46,564 - INFO - httpx - HTTP Request: POST https://api.openai.com/v1/embeddings "HTTP/1.1 200 OK"
2024-03-22 09:52:46,922 - INFO - updater.boot - Popped article : oai:arXiv.org:0803.0966
2024-03-22 09:52:47,291 - INFO - httpx - HTTP Request: POST https://api.openai.com/v1/embeddings "HTTP/1.1 200 OK"
```

Figure 7 – Logs de fonctionnement de l'updater

On remarque la récupération des articles dans la queue et les interrogations de ChatGPT

17. OPENAI, ChatGPT, Embeddings - <https://platform.openai.com/docs/guides/embeddings>

4 Knowledge Graph

4.1 Présentation du Knowledge Graph

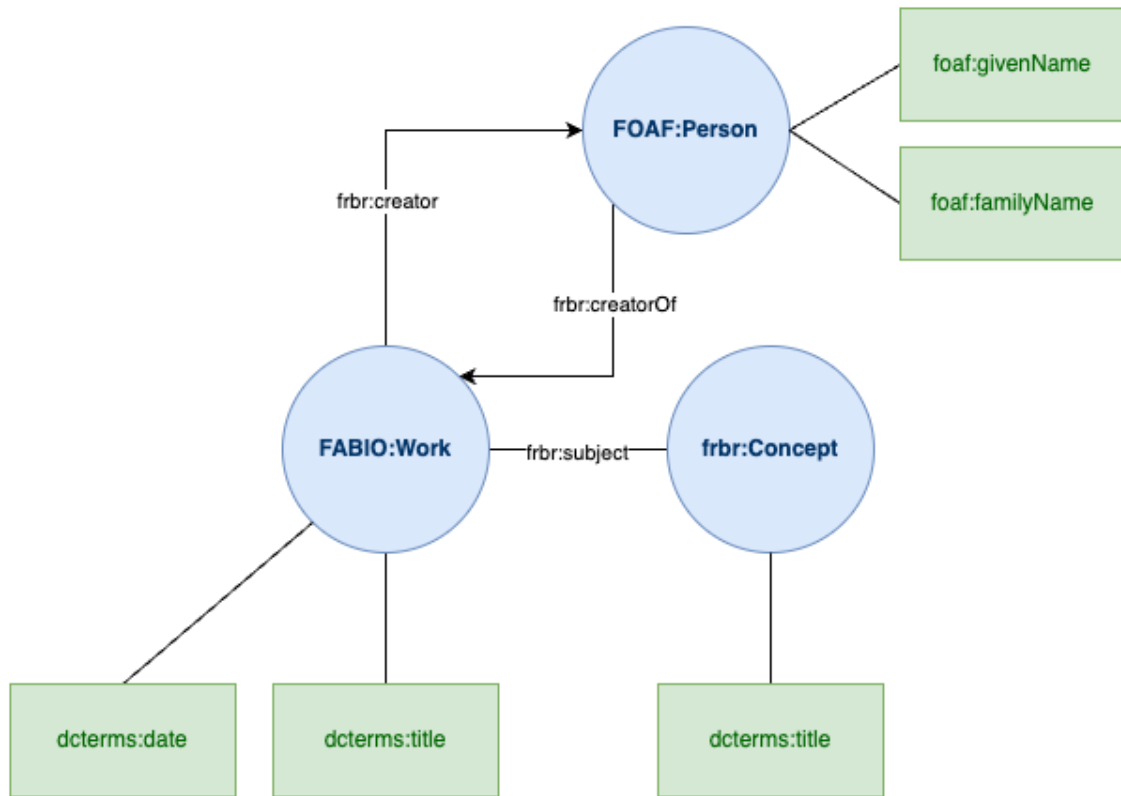


Figure 8 – Knowledge Graph

4.2 Choix du Knowledge Graph

Pour réaliser l'ontologie structurant la connaissance autour des articles récupérés auprès d'Arxiv, nous avons commencé par détailler les informations à notre disposition. Ces données seront traitées et intégrées à des classes d'ontologies existantes ou non (principe de réutilisation).

Nous constatons que les auteurs des articles sont mentionnés, ce qui nous donne le point de départ imposé par le sujet (FOAF¹⁸[3], Friend Of a Friend), pour lequel nous utiliserons `foaf:Person`. Nous traitons la donnée pour extraire

18. FOAF Vocabulary Specification 0.99 - <http://xmlns.com/foaf/0.1/>

le Nom et le Prénom que nous placerons respectivement dans foaf :familyName et foaf :givenName.

Nous avons ensuite recherché une ontologie existante permettant de décrire des articles ou ouvrages. Nous avons optés pour FaBiO ¹⁹[2]) qui décrit des entités publiées ou en cours de publication. Fabio est une ontologie alignée sur FRBR (Functional Requirements for Bibliographic Records ²⁰), qui permet la description des documents ainsi que leur évolution. Elle est largement utilisée par de nombreux organismes dans le monde, notamment la Bibliothèque Nationale de France ²¹ [6].

Pour représenter nos articles et autres travaux issus d'Arxiv, nous avons choisis fabio :Work qui représente une création intellectuelle ou artistique. Cette classe permet d'englober différents types de travaux et écrits. Nous associons à ce travail un titre avec le vocabulaire dcterms :title ²² [1] et les dates associées avec dcterms :date.

Pour réaliser la liaison logique entre les travaux et leurs auteurs, nous allons utiliser des éléments de FRBR. Notre choix se porte sur frbr :creator qui décrit le créateur d'un travail et frbr :creatorOf qui décrit la relation inverse.

Pour compléter l'ontologie avec les éléments fournis par ARXIV, nous ajoutons les sujets traités par le travail. Nous associons donc les sujets des articles à la classe frbr :Concept qui englobe les sujets d'un travail (disciplines, champs de connaissances...). Un éléments de vocabulaire dcterms :title contenant le libellé du sujet est associé.

Pour établir la relation entre fabio :Work et frbr :Concept, nous utilisons frbr :subject qui décrit qu'un article possède un sujet.

19. FaBiO, the FRBR-aligned Bibliographic Ontology - <https://sparontologies.github.io/fabio/current/fabio.html>

20. Expression of Core FRBR Concepts in RDF - <https://vocab.org/frbr/core>

21. Bibliothèque Nationale de France, Modèles FRBR, FRAD et FRSAD - <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad>

22. Dublin Core - <https://www.dublincore.org/specifications/dublin-core/dcmi-terms/>

5 Ingestion d'un article

Les figures ci-dessous explicitent le fonctionnement de l'ingestion d'un article depuis Arxiv :

Ingestion d'un article / Diagramme

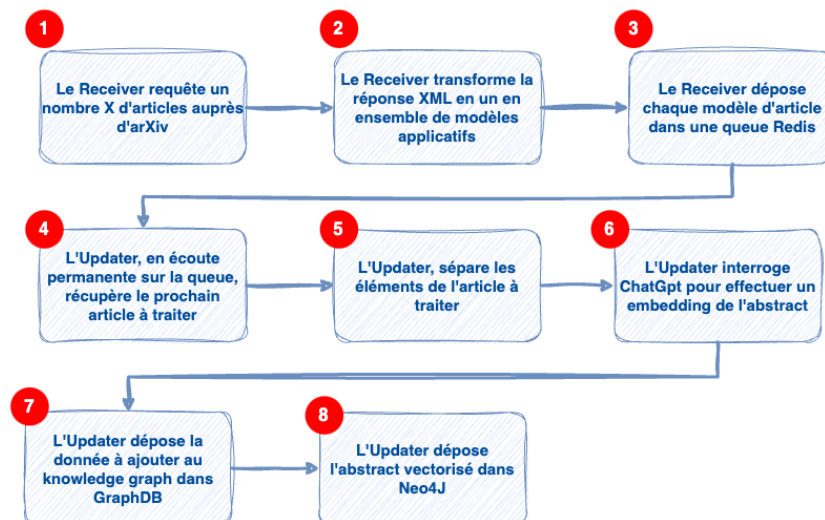
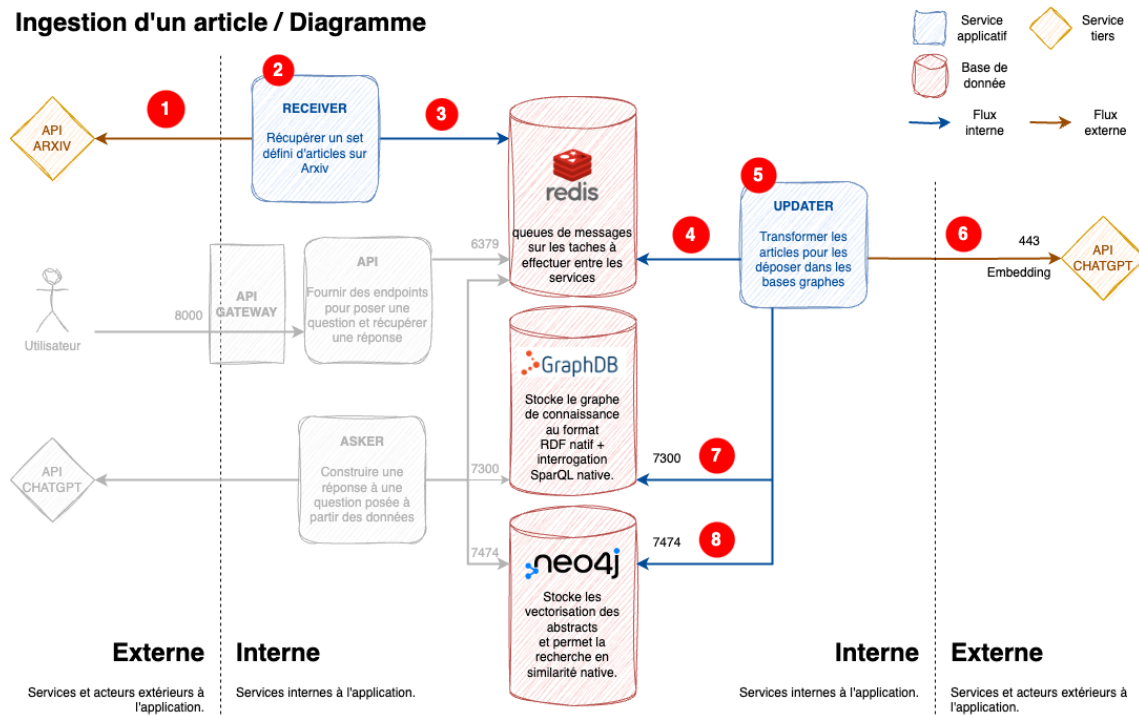


Figure 9 – Ingestion d'un article

6 Génération d'une réponse

Les figures ci-dessous explicitent le fonctionnement de la génération d'une réponse :

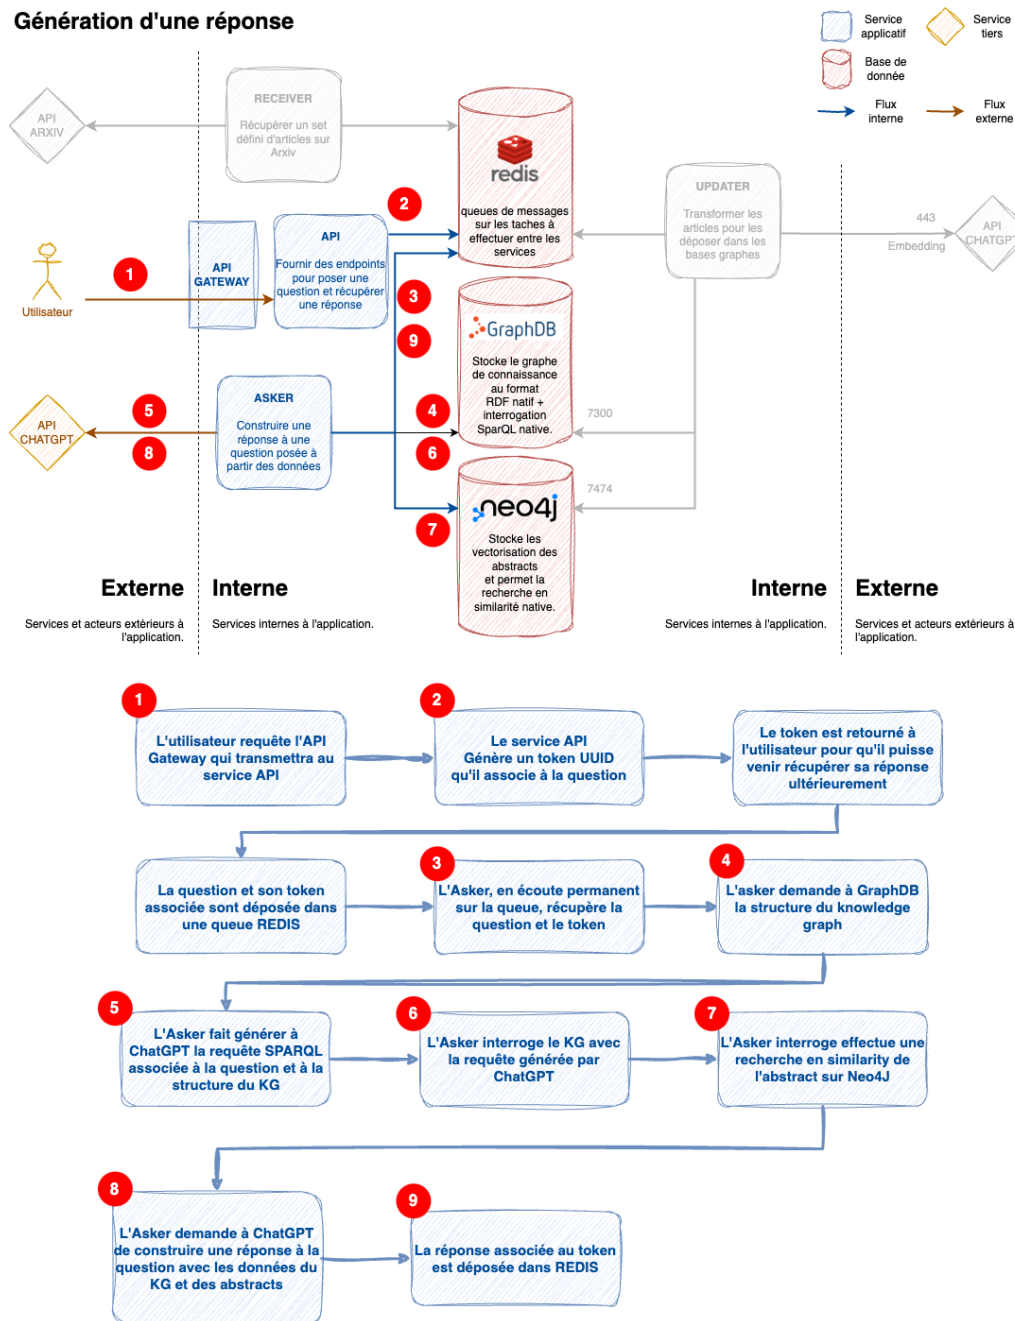


Figure 10 – Génération d'une réponse

6.1 Réponses aux questions

Pour décrire la partie question-réponse du projet, on peut dire que notre système de chaîne de modèles de langage à large échelle fonctionne de manière à fournir des réponses pertinentes et informatives aux questions posées. Toutefois, il est important de noter que malgré les performances satisfaisantes, il existe des limites et des lacunes inhérentes à notre approche.

Notre application peut parfois ne pas être en mesure de fournir des réponses complètes ou précises, en particulier lorsque les informations nécessaires ne sont pas disponibles dans nos sources de données. Dans ces cas, notre système alerte l'utilisateur que les informations requises ne sont pas de son ressort, comme cela a été le cas pour la question sur les origines des domaines techniques.

Malgré ces limitations, notre système fonctionne de manière assez satisfaisante compte tenu des moyens dont nous disposons. Il fournit des réponses basées sur les informations disponibles et tente d'offrir une compréhension approfondie des sujets abordés.

6.1.1 Qui influence qui?

```
{
  "token": "/ask/bee6763e-cd53-4ec4-85db-2fe62abd36c7",
  "state": "Done",
  "question_content": " Qui influence qui ? ",
  "question_answer": "content='Based on the information provided
    from GraphDB, it appears that confidence in rule mining is
    systematically influenced by the frequency of items on the
    left-hand side of rules. Additionally, it is noted that
    the measure known as lift does not perform well in
    filtering out random noise within transaction data. This
    suggests that in the context of rule mining, certain
    metrics and item frequencies play a significant role in
    influencing the outcomes of interest measures.\\n\\n
    Unfortunately, there is no specific information available
    from Neo4J regarding the question of influence. Therefore,
    I cannot provide further details on the influence
    relationships beyond what has been mentioned from the
    GraphDB source.'",
  "start_date": "2024-03-16T12:56:07.640480",
  "finish_date": "2024-03-16T12:56:21.495242"
}
```

6.1.2 Quels sont les meilleurs spécialistes de tel ou tel domaine?

```
{
  "token": "/ask/895aac78-90e9-4ad5-b602-848f9e2111ec",
  "state": "Done",
  "question_content": "Quels sont les meilleurs sp cialistes de  
tel ou tel domaine ?",
  "question_answer": "content='Based on the authoritative  
information provided from GraphDB, we have a list of  
distinguished specialists in various fields. In the realm  
of computer science and discrete mathematics, experts such  
as Derek Corneil, Michel Habib, Christophe Paul, Marc  
Tedder, Veronique Bruyere, and Hadrien Melot have been  
identified. Pierfrancesco La Mura is noted for his  
expertise in quantum physics, computer science and game  
theory, as well as theoretical economics.\\n\\nIn the area  
of computer science and computational geometry, Zachary  
Abel, Hugo A. Akitaya, Scott Duke Kominers, Matias Korman,  
and Frederick Stock are recognized for their contributions.  
These individuals are also acknowledged for their work in  
computer science with multi-agent systems and robotics.  
When it comes to computer science and database systems,  
Michael Hahsler and Kurt Hornik are the specialists to note  
. They are also known for their expertise in statistics and  
machine learning.\\n\\nFrom the similarity search results  
provided by Neo4J, it appears that the best algorithms in a  
certain context run in linear time, although they are  
described as rather complicated. This information, while  
related to algorithmic efficiency, does not specify  
individual specialists or their domain expertise.\\n\\n  
Combining both sources, we have a comprehensive list of  
specialists in their respective fields from GraphDB, and an  
insight into the complexity of the best algorithms from  
Neo4J. If you require further details about the best  
specialists in a specific domain not covered here, I regret  
to inform you that no additional information is available  
at this time.'",
  "start_date": "2024-03-16T12:54:54.753944",
  "finish_date": "2024-03-16T12:55:19.099980"
}
```

6.1.3 Quelles personnes influencent quelles autres personnes?

```
{  
  "token": "/ask/96210048-c2b2-4ebd-a97c-9ae5f33b51b6",  
  "state": "Done",  
  "question_content": " Quelles personnes influencent quelles  
    autres personnes ? ",  
  "question_answer": "content=\"Based on the information  
    retrieved from GraphDB, we can see a complex network of  
    mutual influence among a group of individuals. The  
    relationships indicate that each person listed has an  
    impact on all the others within the group. For instance,  
    Derek Corneil is shown to influence a number of people  
    including Michel Habib, Christophe Paul, and Marc Tedder,  
    among others. Similarly, each of these individuals also  
    exerts influence on Derek Corneil and the rest of the group  
    , creating a web of interconnected influences.\\n\\nFrom  
    the Neo4J database, we have a similarity search result that  
    points to documents discussing the influence of certain  
    factors, such as the frequency of items in the left hand  
    side of rules, on the confidence of those rules. It also  
    mentions that the metric 'lift' may perform poorly in  
    filtering random noise in transaction data. However, this  
    information does not directly address the question of which  
    people influence others, but rather discusses the  
    influence of certain elements within data analysis.\\n\\n  
    Combining these two pieces of information, we can conclude  
    that there is a detailed mapping of influence among a  
    specific set of individuals as provided by GraphDB, while  
    Neo4J offers insights into how certain factors can  
    influence data analysis outcomes. Unfortunately, the latter  
    does not provide information on personal influences  
    between individuals.\"",  
  "start_date": "2024-03-16T12:57:13.699909",  
  "finish_date": "2024-03-16T12:58:09.564078"  
}
```

6.1.4 Qui est à l'origine de tel ou tel domaine technique?

```
{
  "token": "/ask/ce2e2bd8-05d3-4964-9c77-c31849c80d63",
  "state": "Done",
  "question_content": " Qui est l'origine de tel ou tel
    domaine technique ? ",
  "question_answer": "content=\"Based on the information
    provided from GraphDB, it appears that several individuals
    are recognized for their expertise in specific technical
    domains. Corneil Derek, Habib Michel, Paul Christophe,
    Tedder Marc, Bruyere Veronique, and Melot Hadrien are noted
    for their specialization in computer science and discrete
    mathematics. La Mura Pierfrancesco is specialized in
    quantum physics, computer science with a focus on game
    theory, and theoretical economics. Abel Zachary, Akitaya
    Hugo A., Kominers Scott Duke, Korman Matias, and Stock
    Frederick have expertise in computer science with an
    emphasis on computational geometry, multiagent systems, and
    robotics. Hahsler Michael and Hornik Kurt are specialized
    in computer science, particularly in databases, and in
    statistics with a focus on machine learning.\\n\\nHowever,
    the information from Neo4J, which comes from a similarity
    search based on the question, does not provide specific
    details about the origins of these technical domains or who
    exactly founded them. It merely indicates that the problem
    of efficiently computing MD(G) has been investigated since
    the early 70's, which is related to algorithmic graph
    theory, a field within discrete mathematics and computer
    science.\\n\\nIn summary, while we have a list of
    individuals associated with certain technical domains, the
    information at hand does not specify who originally founded
    these domains. If you are seeking the founders or
    originators of these technical fields, I must inform you
    that this information is not available in the data provided
    .\\n\"",
  "start_date": "2024-03-16T12:58:50.626912",
  "finish_date": "2024-03-16T12:59:10.936270"
}
```

7 Limites de l'architecture

La restriction majeure liée à la récupération d'articles réside dans la limitation stricte du nombre d'articles accessibles. Bien que le sujet sous-entende qu'un volume substantiel d'articles doit être pris en compte, il ne mentionne pas explicitement que l'accès à ces articles via l'API de ChatGPT est assujéti à des frais. Cette omission peut induire en erreur quant à la disponibilité illimitée des ressources. Ainsi, il est crucial de prendre en considération les implications financières liées à l'utilisation de l'API pour accéder à un nombre significatif d'articles, et d'envisager des alternatives ou des solutions pour surmonter cette limitation, telles que la sélection judicieuse des articles ou l'optimisation des requêtes pour maximiser l'efficacité de la récupération.

La brique de récupération des articles depuis Arxiv (Retreiver) ne peut être dupliquée en l'état. En effet, de multiples instances effectueraient les mêmes opérations dans le même temps. Cela ne créerait pas de doublons en base mais maintiendrait inutilement de multiples processus effectuant les mêmes actions. Pour résoudre cela, un mécanisme de différenciation du type Master/Worker ou un verrou paramétrique pourraient être implémentés afin de ne faire fonctionner qu'un Retreiver sur les X présents. Les autres instances étant présentes pour s'activer en cas de défaillance de la première.

En raison des simples besoins du projet, les bases de données ne sont pas configurées pour assurer de la haute disponibilité. Si ce besoin venait à émerger, Redis, Neo4j et GraphDB sont en mesure d'assurer, avec les éléments de configuration adéquats, des fonctionnements sous forme de Clusters²³[10]²⁴ [7]²⁵ [4].

23. REDIS, Scale with Redis Cluster - <https://redis.io/docs/management/scaling/>

24. Neo4J, Clustering Operations Manual - <https://neo4j.com/docs/operations-manual/current/clustering/>

25. HraphDB, Cluster Basics - <https://graphdb.ontotext.com/documentation/10.0/cluster-basics.html><https://redis.io/docs/management/scaling/>

8 Conclusion

Dans le cadre de ce rapport, nous avons exploré en détail l'architecture d'ensemble de notre système, mettant en lumière les technologies utilisées, l'ontologie sous-jacente, le processus d'ingestion des articles ainsi que la génération des réponses. Cette analyse approfondie nous a permis de comprendre les fondements et les mécanismes clés qui sous-tendent notre système de réponse automatique basé sur l'intelligence artificielle.

Cependant, tout en reconnaissant les avancées réalisées, il est essentiel de prendre en compte les limites inhérentes à notre architecture. Parmi celles-ci, nous avons identifié la restriction significative liée au nombre d'articles récupérés, ainsi que l'architecture asynchrone autour de Redis et de l'API Gateway. Ces limitations appellent à une réflexion continue et à des améliorations potentielles pour optimiser notre système et répondre aux besoins évolutifs de nos utilisateurs.

En dépit de ces défis, notre architecture offre une base solide pour fournir des réponses précises et pertinentes aux requêtes des utilisateurs. À l'avenir, nous envisageons d'explorer de nouvelles opportunités d'amélioration, telles que l'optimisation des performances, l'extension de l'ontologie pour une compréhension plus profonde des sujets, l'expansion des capacités de récupération d'articles et la synchronisation de l'architecture. Ce faisant, nous nous engageons à maintenir notre engagement envers l'innovation et à offrir une expérience utilisateur exceptionnelle à nos clients.

9 Bibliographie et webographie

Références

- [1] Dublin Core Metadata Initiative Terms. <https://www.dublincore.org/specifications/dublin-core/dcmi-terms/>. Accessed on : Date Accessed.
- [2] FABIO Ontology Documentation. <https://sparontologies.github.io/fabio/current/fabio.html>. Accessed on : Date Accessed.
- [3] FOAF (Friend of a Friend) Vocabulary. <http://xmlns.com/foaf/0.1/>. Accessed on : Date Accessed.
- [4] GraphDB Clustering Basics Documentation. <https://graphdb.ontotext.com/documentation/10.0/cluster-basics.html>. Accessed on : Date Accessed.
- [5] MDN Glossary : UUID. <https://developer.mozilla.org/fr/docs/Glossary/UUID>. Accessed on : Date Accessed.
- [6] Modèles FRBR, FRAD et FRSAD de la Bibliothèque nationale de France. <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad>. Accessed on : Date Accessed.
- [7] Neo4j Clustering Documentation. <https://neo4j.com/docs/operations-manual/current/clustering/>. Accessed on : Date Accessed.
- [8] NGINX API Gateway Documentation. <https://www.nginx.com/learn/api-gateway/>. Accessed on : Date Accessed.
- [9] OpenAI Embeddings Documentation. <https://platform.openai.com/docs/guides/embeddings>. Accessed on : Date Accessed.
- [10] Redis Scaling Documentation. <https://redis.io/docs/management/scaling/>. Accessed on : Date Accessed.
- [11] arXiv. arXiv API Documentation. <https://info.arxiv.org/help/api/index.html>. Accessed on : 10/03/2024.
- [12] arXiv. arXiv Bulk Data Documentation. https://info.arxiv.org/help/bulk_data.html. Accessed on : Date Accessed.
- [13] Open Archives Initiative. OAI-PMH Specification. <http://www.openarchives.org/pmh/>. Accessed on : Date Accessed.
- [14] OpenAI. OpenAI Chat. <https://chat.openai.com/>. Accessed on : Date Accessed.
- [15] World Wide Web Consortium (W3C). SPARQL 1.1 Query Language. <https://www.w3.org/TR/sparql11-query/>. Accessed on : Date Accessed.

10 Annexes

10.1 Annexe I - Table des figures

Table des figures

1	Diagramme de contexte C4	5
2	Diagramme de containers C4	6
3	Contenu de GraphDB	8
4	Contenu de neo4j	9
5	Architecture d'un applicatif	10
6	Logs de fonctionnement du retriever.	10
7	Logs de fonctionnement de l'updater	12
8	Knowledge Graph	13
9	Ingestion d'un article	15
10	Génération d'une réponse	16

10.2 Annexe II - OpenAPI

PFR API - Swagger UI

http://localhost:8000/docs#/ask/get_response_ask_token_get

PFR API 1.0.0 OAS 3.1

[/openapi.json](#)

Made during 2023-2024 school year at CentraleSupélec

API docs for our 'projet fil rouge' 🚀. Don't forget the schemas are at the BOTTOM of the page.

ask

POST /ask/ Post Question

Endpoint to post a question.

Parameters

input_data : PostAskInput The input data containing the content of the question.

Returns

OutputApiAskQuestion The response containing the token, state, and question content.

Parameters Try it out

No parameters

Request body required application/json

Example Value Schema

```
{
  "content": "string"
}
```

Responses

PFR API - Swagger UI

http://localhost:8000/docs#/ask/get_response_ask_token_get

Code	Description	Links
200	Successful Response	No links
	<div>Media type</div> <div>application/json</div> <div>Controls Accept header.</div> <div>Example Value Schema</div> <div><pre>{ "token": "string", "question_content": "string"}</pre></div>	
422	Validation Error	No links
	<div>Media type</div> <div>application/json</div> <div>Example Value Schema</div> <div><pre>{ "detail": [{ "loc": ["string", 0], "msg": "string", "type": "string" }]}</pre></div>	

GET	/ask/<token> Get Response	⌵
Endpoint to get a response to a question.		
Parameters		
input_data : GetAskInput The input data containing the token associated with the question.		
Returns		
OutputApiAskQuestion : OutputRedisApiAskQuestion The state of your question		
Parameters		Try it out

PFR API - Swagger UI

http://localhost:8000/docs#/ask/get_response_ask_token_get

Name	Description
token <small>★ required</small> string (query)	<input type="text" value="token"/>

Responses

PFR API - Swagger UI

http://localhost:8000/docs#/ask/get_response_ask_token_get

Schemas		Links
Code	Description	
200	HTTPValidationError <small>Collapse all</small> object	No links
	<div><div>detail <small>Collapse all</small> array<object></div><div>Items <small>Collapse all</small> object</div><div>loc* <small>Collapse all</small> array<(string integer)></div><div>Example Value <small>Collapse all</small> (string integer)</div><div><pre>{ "token": "string", "state": "pending", "question_content": "string", "question_answer": "None", "start_date": "2024-03-22T09:54:54.949Z", "finish_date": "2024-03-22T09:54:54.949Z" }</pre></div></div>	
422	Validation Error <small>Collapse all</small> object	No links
	<div><div>OutputRedisApiAskQuestion <small>Collapse all</small> object</div><div><p>Represent an key value that is posted with SET Method of Redis db. It is used with post /ask/ endpoint. It is posted to redis as key value to be later changed as an answer to the question is found. It will be used by someone that has to write code to retrieve the response from the user.</p></div><div>Example Value <small>Collapse all</small> Schema</div><div>token* <small>Collapse all</small> string</div><div>The {</div><div>state <small>Collapse all</small> [</div><div>The {</div><div>Def: "loc": [</div><div>questi], ^</div><div>The "msg": "string",</div><div>questi "type": "string"</div><div>The }]</div><div>The }</div><div>Default "None"</div><div>start_date <small>Collapse all</small> (string null)</div><div>Any of <small>Collapse all</small> (string null)</div><div>#0 string date-time</div><div>#1 null</div><div>finish_date <small>Collapse all</small> (string null)</div><div>Any of <small>Collapse all</small> (string null)</div><div>#0 string date-time</div><div>#1 null</div></div>	

PFR API - Swagger UI

http://localhost:8000/docs#/ask/get_response_ask_token_get**PostAskInput** ^ Collapse all **object**

Schema for the input data required for posting a question.

Attributes

content : str The content of the question.

content* ^ Collapse all **string** >= 5 characters

The question you want to ask

PostOutputApiAskQuestion ^ Collapse all **object**

Represents an entry retrieved from arXiv. Generally used to validate incoming data to ensure types and rules. It is put in the redis queue used to post question from the API. It is given also as a response to the user who asked a question.

Parameters

token: UUID4 Unique identifier of the record

state: str, optional State of the question (default is "pending")

question_content: str Content of the question, must be at least 5 characters long

Returns

None

token* ^ Collapse all **string** **uuid4**

The token which you will use to get the answer to your question

question_content* ^ Collapse all **string** >= 5 characters

The content of the question you asked

ValidationError ^ Collapse all **object**

loc* ^ Collapse all **array<(string | integer)>**

Items ^ Collapse all **(string | integer)**

Any of ^ Collapse all **(string | integer)**

#0 **string**

#1 **integer**

msg* **string**

type* **string**